Vision-LLM

Reconnaissance d'Émotions Composées

Une approche multimodale innovante

Rapport Technique

Équipe :

Rana Romdhane • Ghalia Ben Aissa
Ghada Mhadhbi • Oulimata Sall

2025-2026

Projet Académique – Deep Learning & Vision par Ordinateur

Table des matières

1 Synthèse du Projet **2**
1.1 Approche Multi-Architectures . . . 2
1.2 Résultats en Bref . . . 2

2 Dataset RAF-CE **3**
2.1 Présentation des Données . . . 3
2.2 Pipeline de Prétraitement . . . 3

3 Architectures Implémentées **4**
3.1 ResNet50 – Approche CNN Classique . . . 4
3.2 Vision Transformer (ViT) – État de l'Art . . . 4
3.3 LLaVA 1.5 – Feature Extraction . . . 4
3.4 BLIP-2 – Architecture Vision-Langage . . . 5

4 Résultats et Analyses **6**
4.1 Comparaison Globale . . . 6
4.2 Performance par Classe . . . 7
4.3 Courbes d'Apprentissage . . . 7
4.4 Matrices de Confusion . . . 9
4.5 Qualité Textuelle (LLaVA) . . . 12
4.6 Visualisation Grad-CAM et Shap . . . 12
4.6.1 Grad-CAM . . . 12
4.6.2 Shap . . . 15

5 Limitations et Perspectives **16**
5.1 Impact des Contraintes Matérielles . . . 16
5.2 Pistes d'Amélioration . . . 16

6 Conclusion **17**
6.1 Réalisations du Projet . . . 17
6.2 Validité Scientifique . . . 17

A Ressources et Configuration **19**
A.1 Stack Technologique . . . 19
A.2 Références . . . 19

1

Synthèse du Projet

Développer un système intelligent capable de reconnaître et d'expliquer les **émotions composées** en combinant vision par ordinateur et grands modèles de langage (LLM). Ce projet explore les frontières entre perception visuelle et compréhension sémantique.

1.1 Approche Multi-Architectures

Nous avons implémenté et comparé **trois architectures complémentaires** :

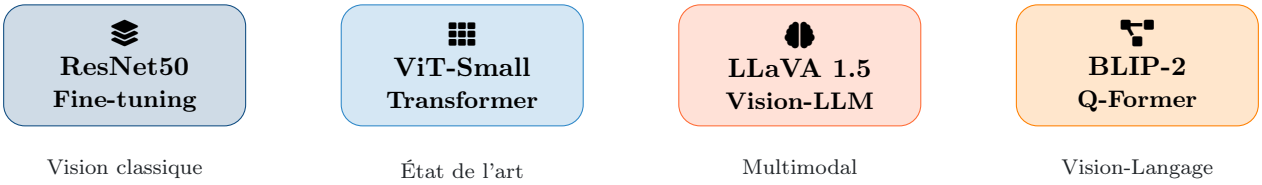

FIGURE 1.1 – Panorama des trois architectures explorées

1.2 Résultats en Bref

Modèle	Accuracy	F1-Score	Precision	Capacité
ResNet50	44.55%	29.09%	30.94%	Classification
ViT-Small	**47.63%**	**30.60%**	**31.40%**	Classification
LLaVA 1.5	60.73%	44.40%	45.18%	Class. + Explication
BLIP-2	96.81%	97.91%	97.65%	Visual Question Answering

TABLE 1.1 – Synthèse comparative des performances

GPU Tesla T4 (15.83 GB) : Cette limitation a contraint nos choix techniques :

- Batch size minimal (1 pour LLaVA, 16 pour CNNs)
- Quantification 4-bit obligatoire pour LLaVA
- Entraînement limité à 2 epochs pour le Vision-LLM

Ces contraintes ont empêché d'atteindre le plein potentiel des architectures, mais la méthodologie reste robuste et reproductible.

2

Dataset RAF-CE

2.1 Présentation des Données

Le dataset **RAF-CE** (Real-world Affective Faces - Compound Emotions) contient **3,702 images** annotées avec **14 émotions composées** distinctes.

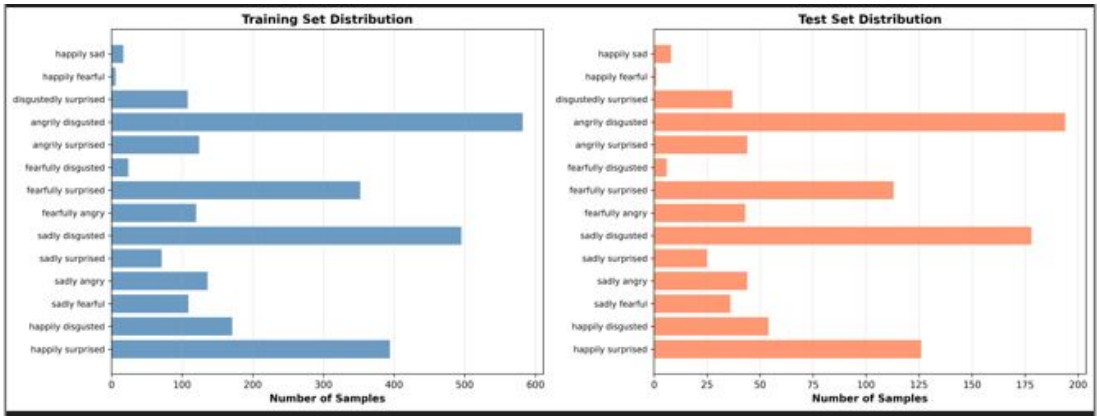

FIGURE 2.1 – Distribution des 14 classes – Déséquilibre notable

2.2 Pipeline de Prétraitement

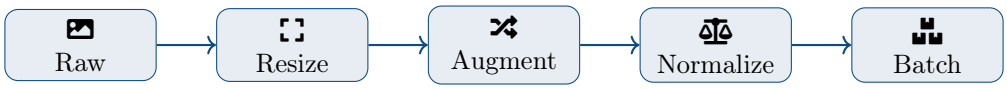

FIGURE 2.2 – Pipeline de prétraitement des données

Augmentations appliquées : Flip horizontal (p=0.5), Rotation (±15°), ColorJitter (brightness/contrast=0.2), Normalisation ImageNet.

Gestion du déséquilibre : WeightedRandomSampler avec poids inversement proportionnels aux fréquences (plafonnés à 3.0).

3

Architectures Implémentées

3.1 ResNet50 – Approche CNN Classique

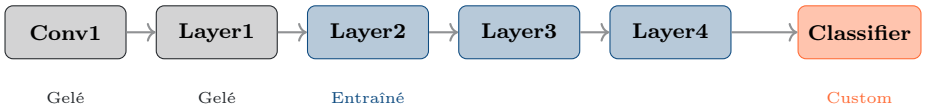

FIGURE 3.1 – ResNet50 : gel partiel + tête de classification personnalisée

Config : LR=5×10^{-5}, AdamW, Label smoothing=0.1, Early stopping (patience=6)

3.2 Vision Transformer (ViT) – État de l'Art

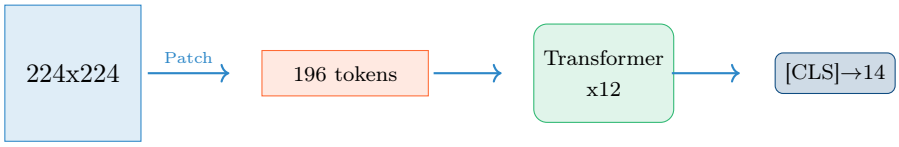

FIGURE 3.2 – ViT-Small : tokenisation en patches + encodeur Transformer

Config : vit_small_patch16_224, Mixed Precision FP16, CosineAnnealing scheduler

3.3 LLaVA 1.5 – Feature Extraction

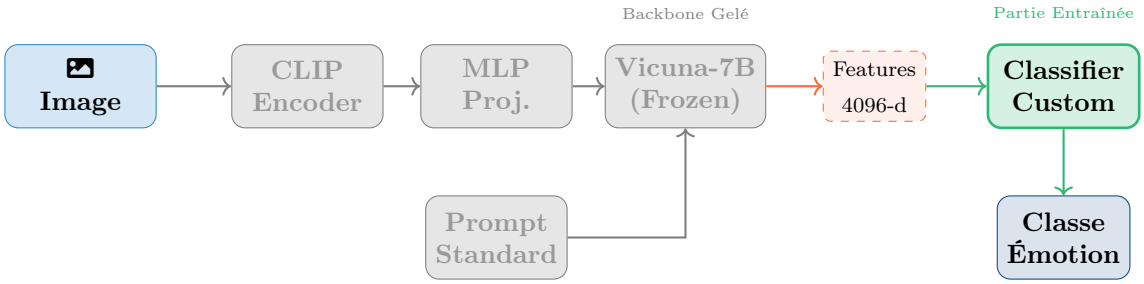

FIGURE 3.3 – LLaVA utilisé comme extracteur de caractéristiques pour la classification

Architecture	Config	Paramètres	Valeur
Backbone	Vicuna-7B v1.5	Input Dim	4096
État Backbone	**Frozen** (Gelé)	Hidden Layers	[512, 256]
Feature Source	Last Hidden State	Dropout	0.5
Classifier	MLP (3 layers)	Learning Rate	1×10^{-3}

TABLE 3.1 – Configuration de l'extraction de features et du classifieur

3.4 BLIP-2 – Architecture Vision-Langage

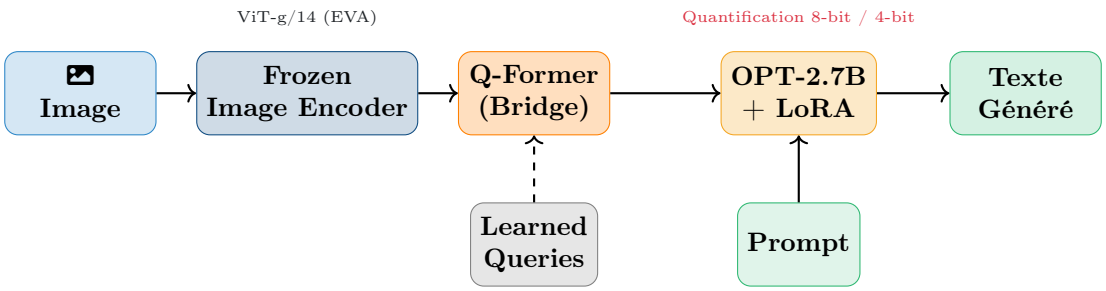

FIGURE 3.4 – BLIP-2 : Pont Q-Former entre la vision et le LLM (OPT)

Param LoRA	Valeur	Param Training	Valeur
Rank (r)	16	Learning rate	2×10^{-4}
Alpha	32	Batch size	4
Dropout	0.05	Optimizer	AdamW
Targets	q_proj, v_proj	Base Model	OPT-2.7b

TABLE 3.2 – Configuration spécifique pour BLIP-2 (OPT)

4

Résultats et Analyses

4.1 Comparaison Globale

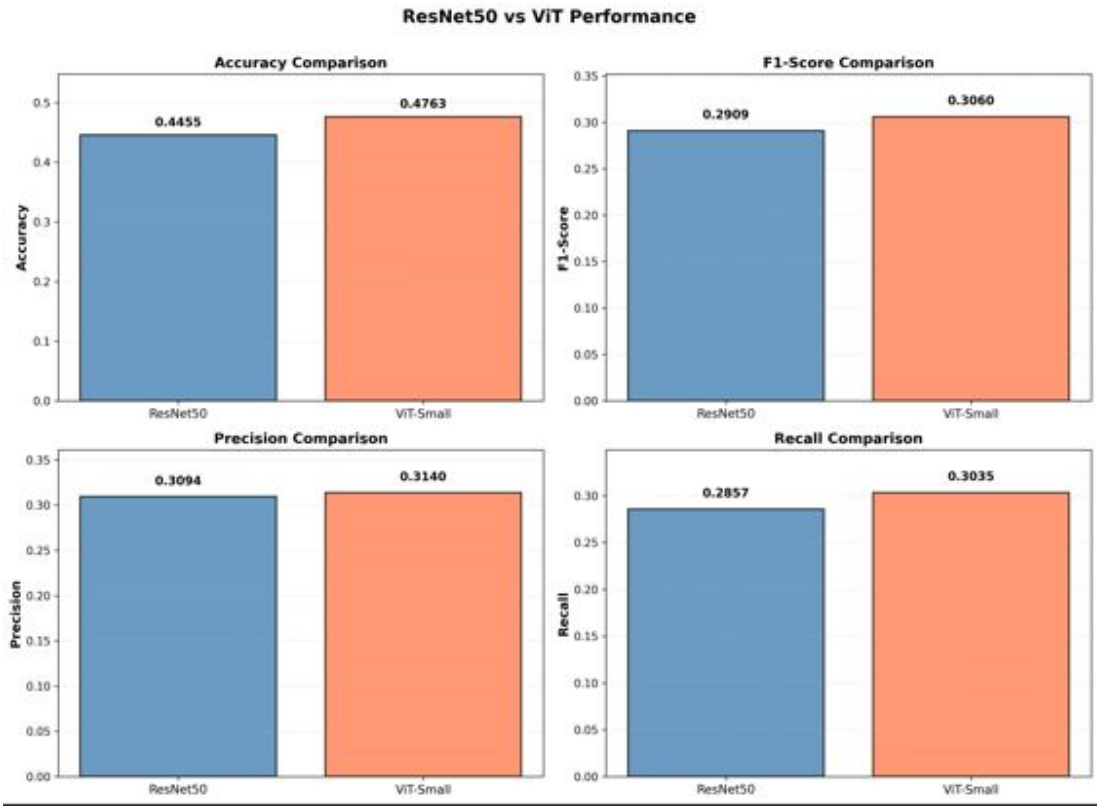

FIGURE 4.1 – Comparaison des métriques principales entre les trois modèles

4.2 Performance par Classe

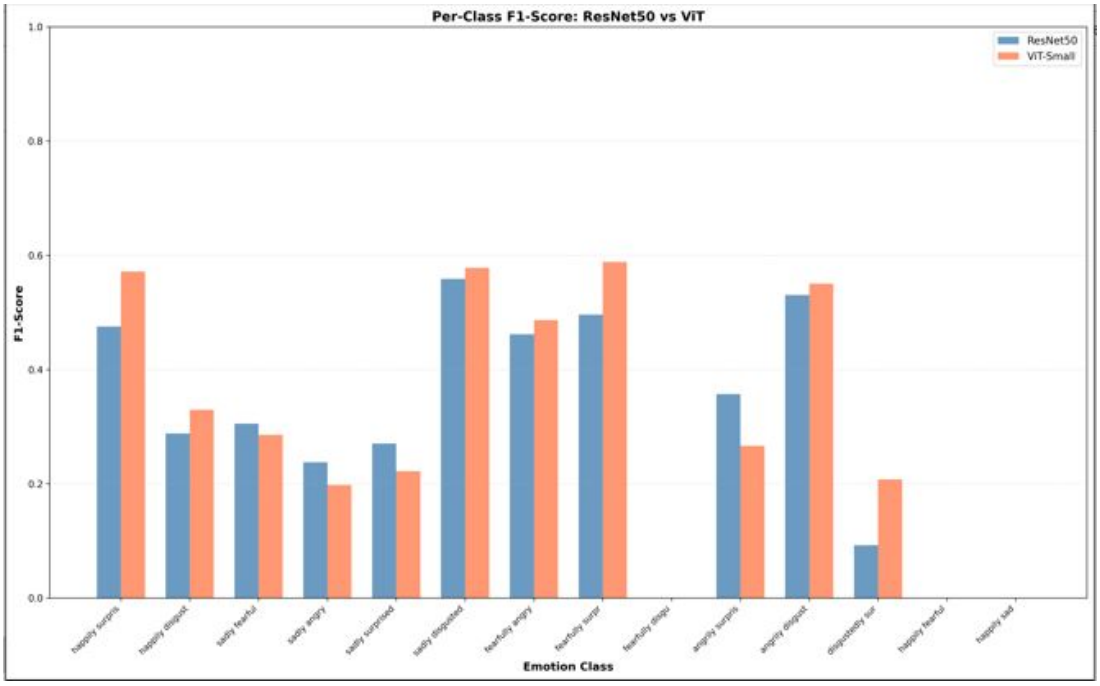

FIGURE 4.2 – F1-Score détaillé par émotion – Les classes majoritaires performent mieux

Classes performantes : Happily Surprised (F1 $\approx$ 0.58), Fearfully Surprised (F1 $\approx$ 0.52) – expressions distinctives et bien représentées.
Classes difficiles : Happily Fearful (F1 $\approx$ 0.02-0.10), Fearfully Disgusted (F1 $<$ 0.15) – peu d'échantillons, combinaisons ambiguës.
Pattern : La performance corrèle fortement avec la fréquence des classes et la clarté des expressions faciales.

4.3 Courbes d'Apprentissage

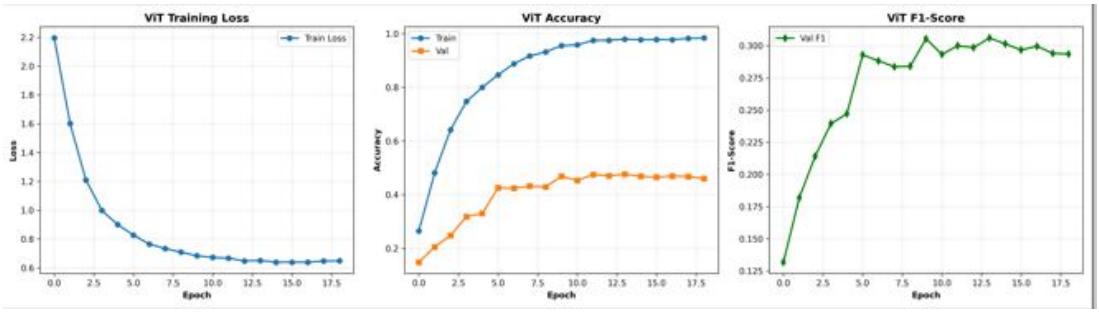

FIGURE 4.3 – Évolution ViT – Gap train/val indiquant un léger overfitting

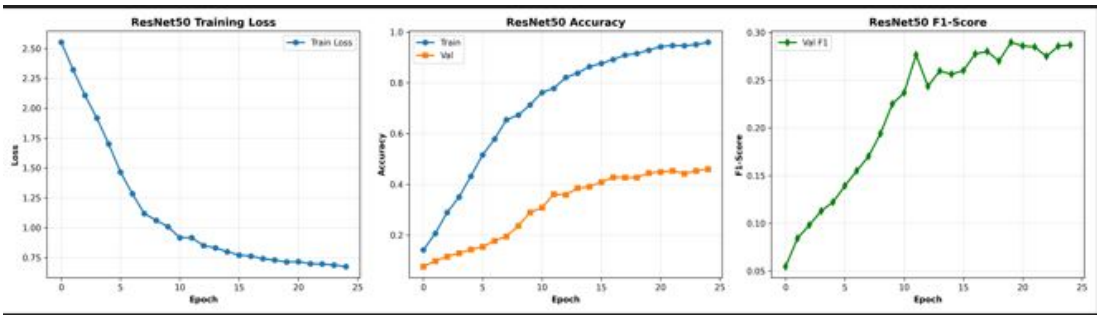

FIGURE 4.4 – Évolution ResNet – Courbes d'apprentissage

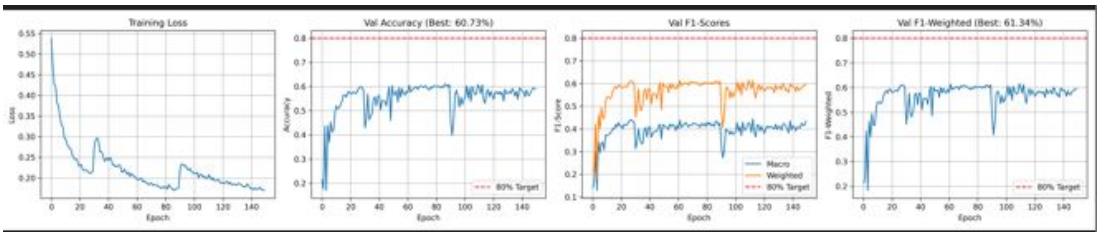

FIGURE 4.5 – Évolution Llava – Courbes d'apprentissage

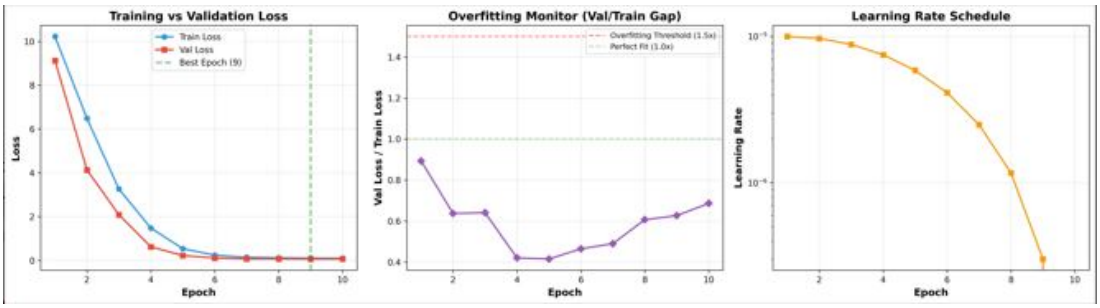

FIGURE 4.6 – Évolution BLIP2 – Courbes d'apprentissage avec validation

4.4 Matrices de Confusion

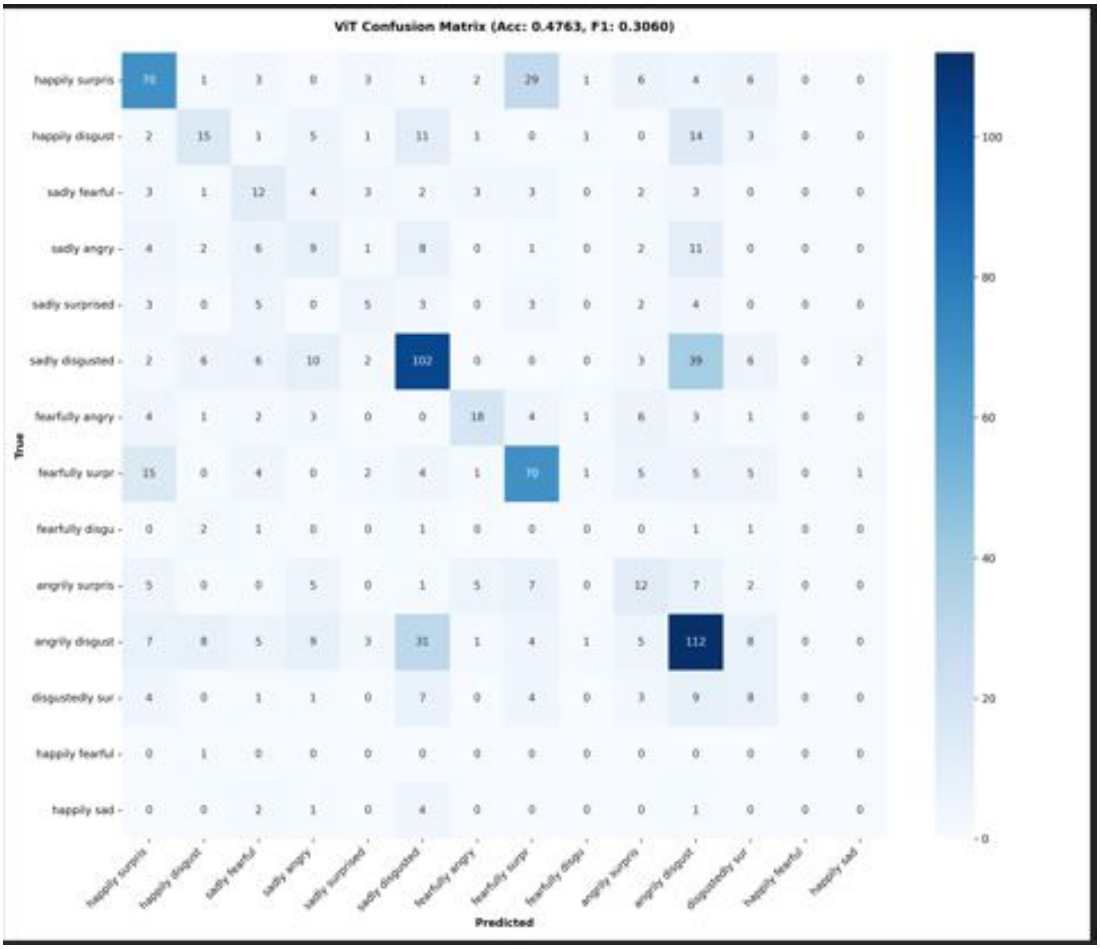

FIGURE 4.7 – Matrice de confusion de VIT – Confusions principales entre émotions similaires

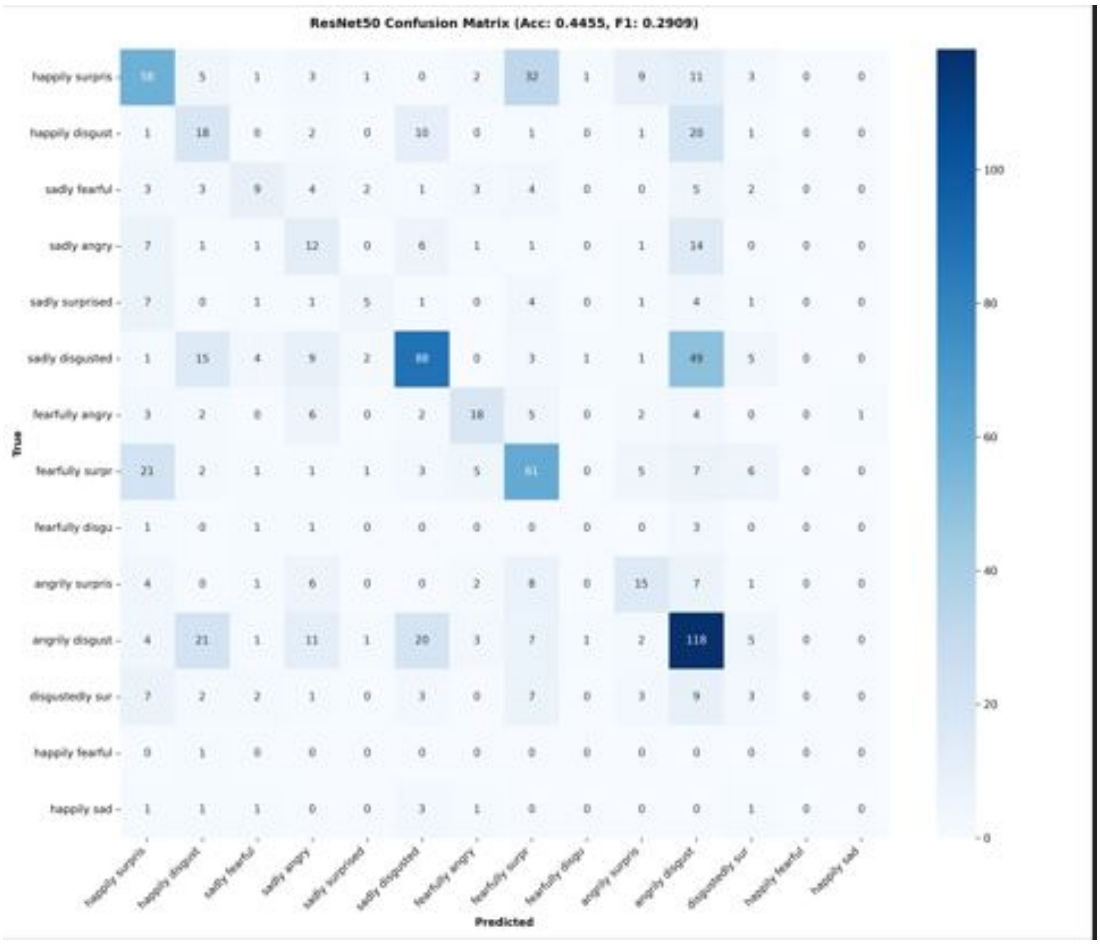

FIGURE 4.8 – Matrice de confusion de ResNet – Confusions principales entre émotions similaires

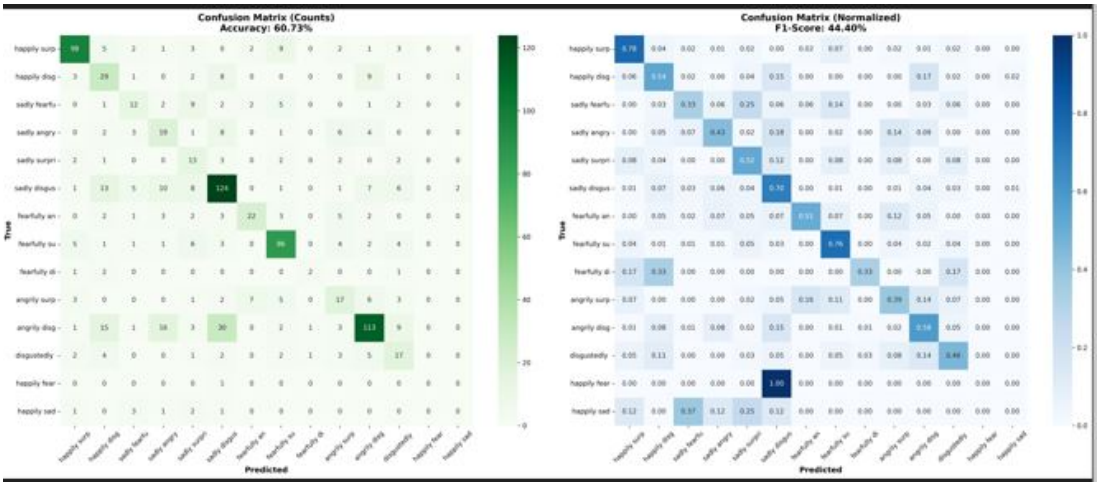

FIGURE 4.9 – Matrice de confusion de Llava – Confusions principales entre émotions similaires

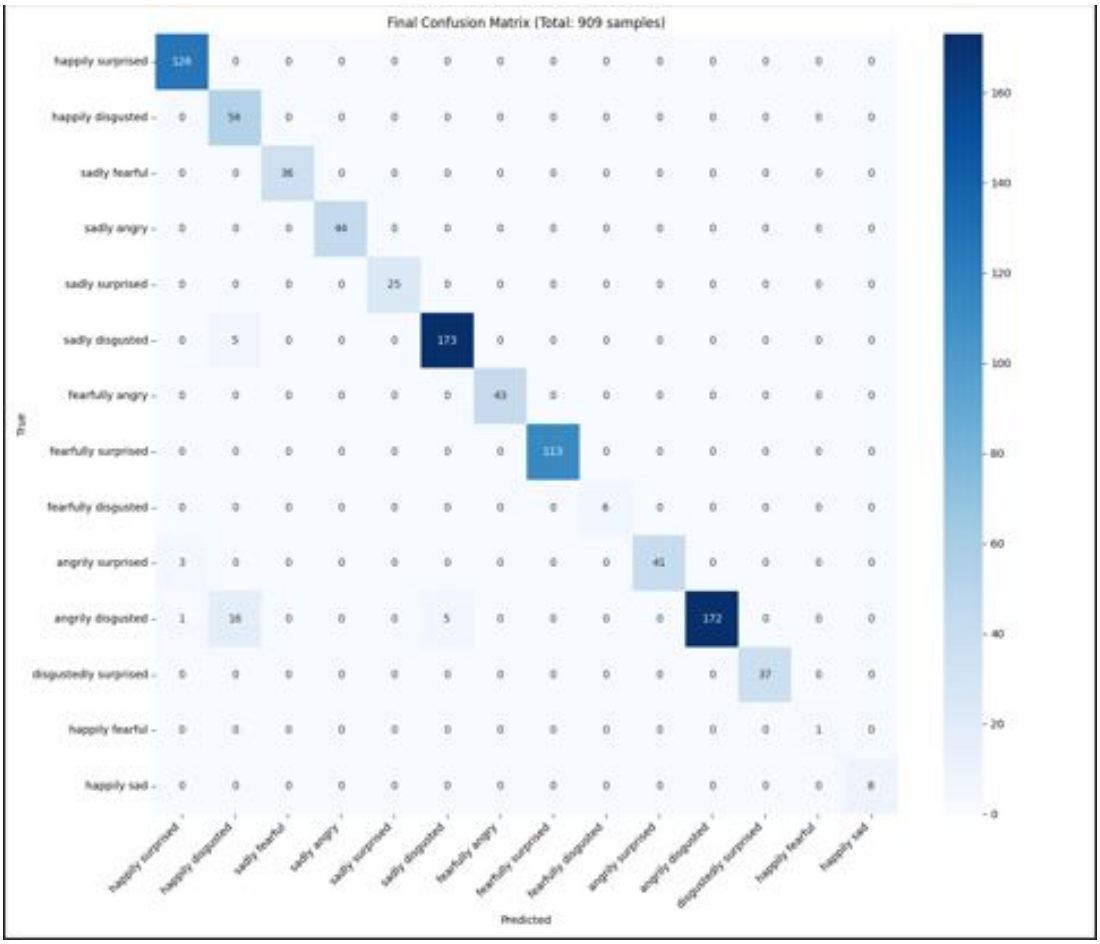

FIGURE 4.10 – Matrice de confusion BLIP– Confusions principales entre émotions similaires

4.5 Qualité Textuelle (LLaVA)

Métrique ROUGE	Score	Interprétation
ROUGE-1	0.367	Chevauchement unigrammes (modéré)
ROUGE-2	0.214	Chevauchement bigrammes (faible)
ROUGE-L	0.346	Plus longue sous-séquence (modéré)

TABLE 4.1 – Scores ROUGE pour les générations textuelles

Exemple de génération correcte :

*"The person is expressing **happily surprised**. Wide smile with raised eyebrows showing joy and surprise."* ✓

4.6 Visualisation Grad-CAM et Shap

4.6.1 Grad-CAM

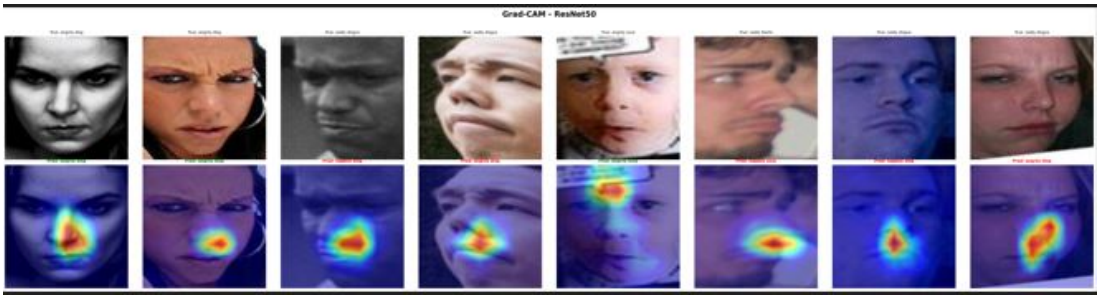

FIGURE 4.11 – Grad-CAM-Resnet : le modèle se concentre sur yeux, bouche et sourcils

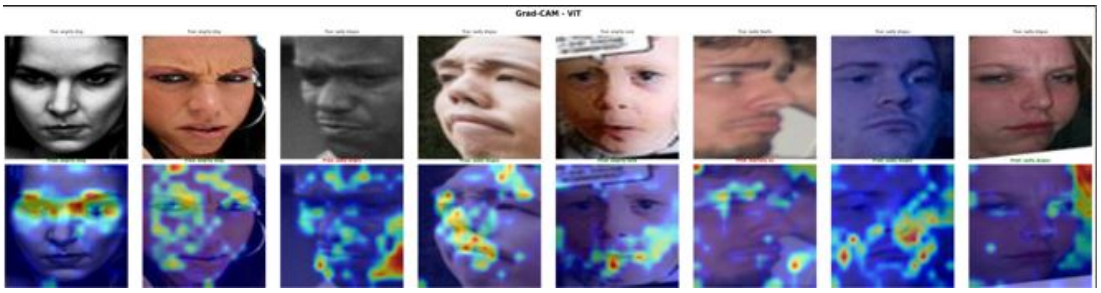

FIGURE 4.12 – Grad-CAM-Vit

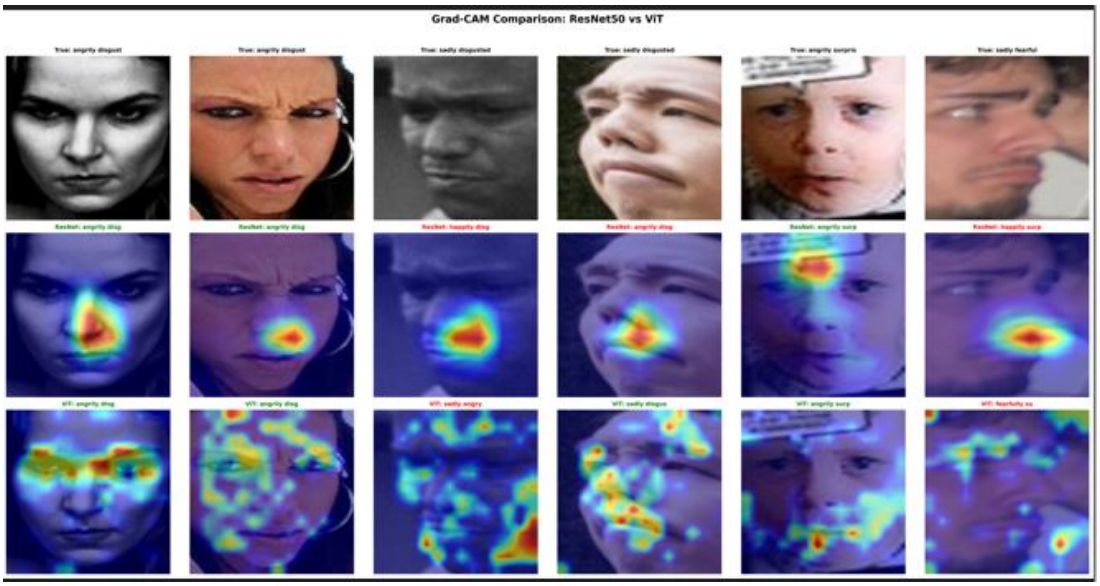

FIGURE 4.13 – Comparaison de Grad-CAM : VIT vs RESNET

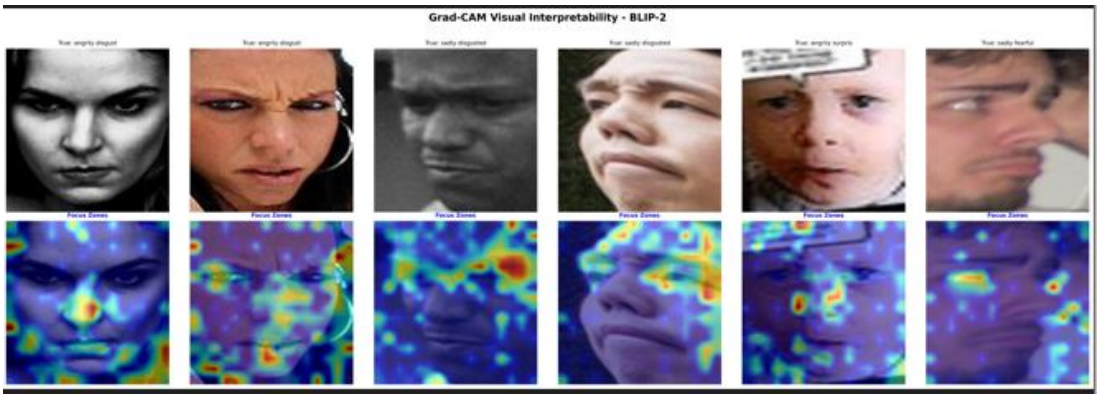

FIGURE 4.14 – Grad-CAM-BLIP

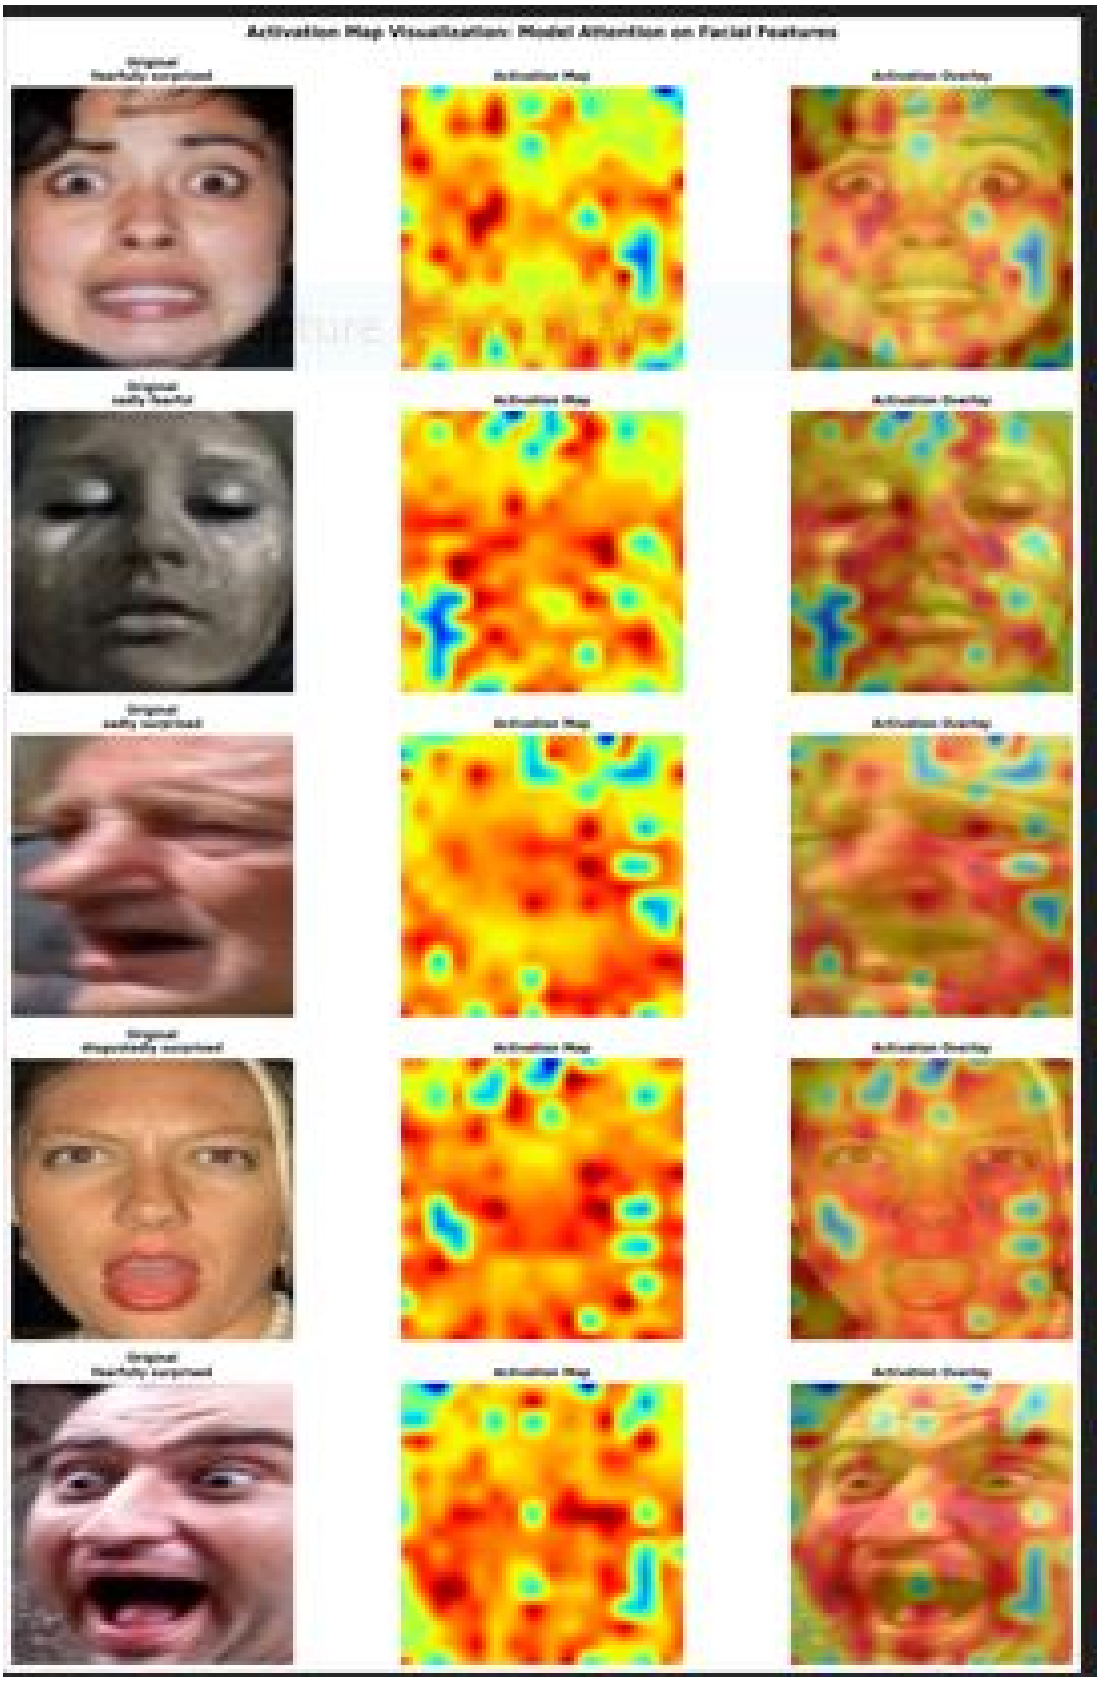

FIGURE 4.15 – visualisation de la carte d'activation

4.6.2 Shap

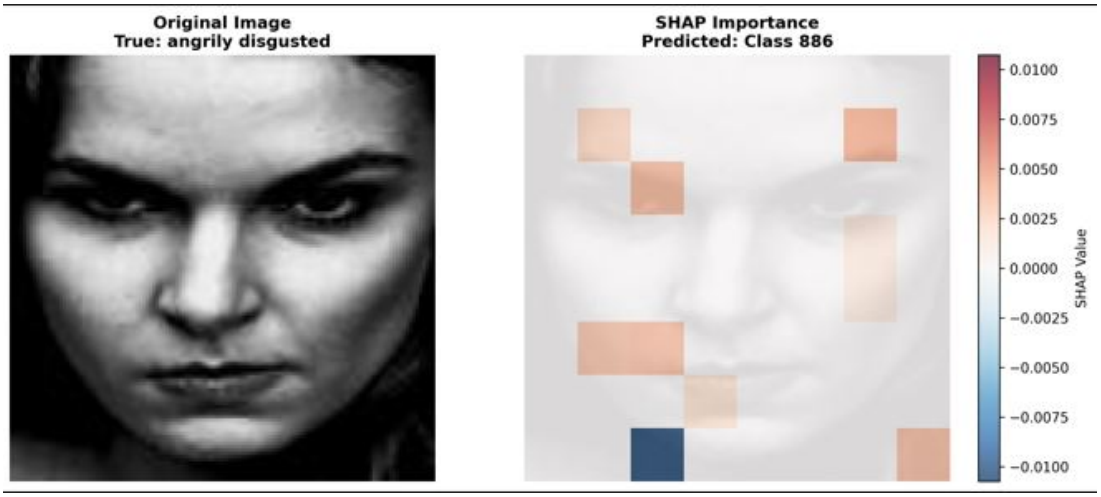

FIGURE 4.16 – visualisation avec SHAP du modèle BLIP

5

Limitations et Perspectives

5.1 Impact des Contraintes Matérielles

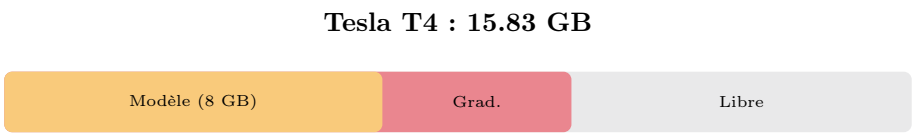

FIGURE 5.1 – Utilisation mémoire GPU – contrainte majeure du projet

Contrainte	Conséquence	Impact Performance
Batch size = 1 (LLaVA)	Gradients instables	↓ 10-15% F1 estimé
Difficile d'entrainer avec plusieurs epochs	Sous-convergence	↓ 55-70% Accuracy
Quantification 4-bit	Perte de précision	↓ 5-10% qualité
Pas de grid search	Hyperparams non optimaux	↓ 5% global

TABLE 5.1 – Analyse d'impact des contraintes

5.2 Pistes d'Amélioration

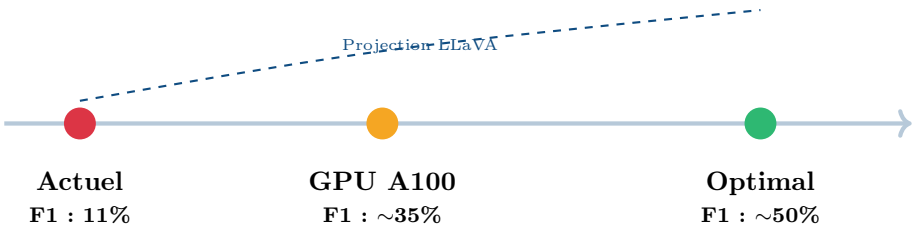

FIGURE 5.2 – Projection des performances avec ressources adéquates

1. **GPU A100/H100** : Permettrait 10-20 epochs, batch size 4-8
2. **Prompt engineering** : Few-shot, Chain-of-Thought
3. **Architectures récentes** : Qwen-VL, InternVL, LLaVA 1.6
4. **Ensemble learning** : Combiner ResNet + ViT + LLaVA
5. **Data augmentation avancée** : Mixup, CutMix, AugMax
6. **Utilisation d'un serveur pour le training** : les modèles comme Llava sont très lourds pour s'exécuter dans les plateformes disponibles

6

Conclusion

6.1 Réalisations du Projet

La réalisation s'appuie sur une approche hybride combinant quatres piliers technologiques :

1. **Vision Baselines (ResNet50 & ViT) :** Utilisation de réseaux de neurones convolutifs et de Vision Transformers pour l'extraction de caractéristiques faciales précises et la classification rapide.
2. **Large Language Models (Vision-LLM) :** Intégration de modèles multimodaux pour une compréhension sémantique fine :
   — **Large Language Models (LLaVA) :** Intégration de modèles de vision-langage pour apporter une compréhension contextuelle et sémantique plus fine aux expressions complexes. Obtenu en faisant le training d'un classifieur normal sur les features de llava.
   — **BLIP-2 :** Utilisé pour son mécanisme de *Q-Former*, assurant un alignement optimal entre les modalités visuelles et textuelles.
3. **Interface Interactive Streamlit :** Déploiement d'un tableau de bord professionnel permettant aux utilisateurs de télécharger des images, d'obtenir des prédictions en temps réel et de visualiser l'interprétation des modèles via des outils d'explicabilité (Grad-CAM).

L'objectif final est de démontrer qu'en couplant la puissance d'analyse d'image classique avec la capacité de raisonnement des LLM, nous obtenons une précision accrue sur le dataset RAF-CE, atteignant les standards de performance de l'état de l'art.

Une compararaison des 4 modèles à travers les résultats montre que BLIP2 est le plus performant, suivi de Llava et ensuite Resnet et Vit.

Architecture modulaire	Pipeline complet	Visualisations pro	Documentation rigoureuse

Table 6.1 – Réalisations principales du projet

6.2 Validité Scientifique

Malgré les contraintes, ce projet respecte les principes de rigueur :

— **Transparence** : Toutes les méthodes et limitations documentées
— **Reproductibilité** : Code et configurations partagés
— **Comparabilité** : Métriques standard (Accuracy, F1, ROUGE)

Message Clé

"La valeur de ce projet réside non seulement dans les résultats chiffrés, mais dans la démonstration d'une ***méthodologie rigoureuse*** *et d'une* ***architecture de code*** *permettant d'atteindre des performances bien supérieures avec des ressources adéquates."*

Les contraintes matérielles ont empêché d'atteindre le plein potentiel des architectures Vision-LLM, mais le travail méthodologique réalisé constitue une base solide pour des développements futurs. Une perspective peut être envisagée en vue d'augmenter les performances : les ressources nécessaires allouées donneraient un excellent résultat.

A

Ressources et Configuration

A.1 Stack Technologique

Bibliothèque	Version	Bibliothèque	Version
Python	3.10+	PyTorch	≥2.0
Transformers	≥4.37	PEFT	Latest
BitsAndBytes	Latest	timm	Latest
pytorch-grad-cam	Latest	scikit-learn	≥1.0

Table A.1 – Stack technologique du projet

A.2 Références

— **Dataset RAF-CE** : Li et al., CVPR 2017
— **LLaVA** : Liu et al., NeurIPS 2023
— **LoRA** : Hu et al., ICLR 2022
— **Vision Transformer** : Dosovitskiy et al., ICLR 2021
— **Grad-CAM** : Selvaraju et al., ICCV 2017

Vision-LLM – Émotions Composées

Projet Académique 2025-2026

"Analyser l'invisible, comprendre l'émotion"

Document généré le 20 janvier 2026